Q-Learning en Cliff Walking

¿Cómo ejecutar el código?

La implementación se encuentra en el archivo solucion.py. Para correrlo, simplemente hay que abrir la terminal en la carpeta del proyecto y ejecutar:

python solucion.py

El script usa los parámetros indicados (alpha=0.5, gamma=1.0, epsilon=0.1) durante 500 episodios. Al finalizar, imprimirá el retorno obtenido y generará automáticamente el archivo recompensas.csv con el historial del entrenamiento.

Respuestas a las preguntas

1. ¿Por qué el camino de 13 pasos es el óptimo? Porque cada paso normal te resta 1 punto, pero caerte al precipicio te resta 100. Entonces, la estrategia que te quita menos puntos es bordear el acantilado. Si subes un cuadrito, avanzas 11 hacia la derecha y bajas a la meta, haces exactamente 13 movimientos seguros, lo que da un retorno de -13. No se puede hacer en menos pasos sin caerse.

2. ¿Por qué la curva de entrenamiento puede estar por debajo de -13? Porque durante la fase de entrenamiento todavía estamos explorando (usamos un epsilon de 0.1). Eso significa que a veces el agente toma decisiones al azar y termina tirándose al acantilado por error, bajando mucho el promedio. El retorno de -13 se saca al final, cuando ya usamos una política 100% "greedy" (donde epsilon es 0 y ya no se explora).

3. ¿Qué pasa cuando el agente cae por el borde? El juego no se termina ahí. Si el agente cae, recibe la recompensa de -100 pero es regresado inmediatamente a la casilla de inicio (S). Por eso, en la fórmula de Q-learning, el estado siguiente s' es el inicio, y se usa el valor máximo de las acciones desde ahí. La única forma de que el valor futuro sea cero es cuando por fin se llega a la meta (G), porque ese sí es el final definitivo del episodio.